

UNIVERSIDAD PRIVADA DEL VALLE

FACULTAD DE INFORMÁTICA Y ELECTRÓNICA

INFORME TÉCNICO DE EXAMEN PRÁCTICO INDIVIDUAL SEGUNDO MOMENTO EVALUATIVO

Ingeniería, Modelado y Procesamiento Analítico Distribuido con Apache Hive
Dataset: Sample - Superstore (9,994 Registros Comerciales)

Estudiante:	Ronald Joel Saavedra Vargas
Código Estudiantil / Email:	svr0035567@est.univalle.edu
Asignatura:	Tecnologías Emergentes I
Fecha de Ejecución y Entrega:	11 de noviembre de 2026

1. Objetivo y Justificación Técnica

El presente proyecto desarrolla de manera integral la solución al Examen Práctico Individual del Segundo Momento de la asignatura Tecnologías Emergentes I. El objetivo primordial consiste en aplicar metodologías rigurosas de ingeniería de datos, modelado dimensional, auditoría de calidad, procesamiento distribuido y consultas analíticas avanzadas sobre el dataset comercial Superstore Sales (Sample Superstore), compuesto por 9,994 transacciones.

El trabajo demuestra solvencia técnica en el lenguaje HiveQL (Apache Hive 4.0.1 sobre Hadoop 3.4.1), implementando expresiones de tabla común (CTE), funciones analíticas de ventana (LAG, RANK, DENSE_RANK, SUM/AVG OVER), segmentaciones avanzadas de clientes mediante el modelo RFM (Recency, Frequency, Monetary), análisis de sensibilidad econométrica de descuentos comerciales, series de tiempo mensuales y la verificación empírica de la regla 80/20 de Pareto.

Arquitectura Dual: Contenedores Docker y Motor Standalone

Para responder a las condiciones de infraestructura reales, el proyecto incorpora una Arquitectura Dual certificada:

1. Infraestructura Contenerizada Clúster (Docker Compose): Diseñada para clústeres distribuidos en producción, compuesta por NameNode (puerto 9870), DataNode, Hive Metastore con catálogo relacional Derby (puerto 9083) y HiveServer2 con interfaz JDBC Beeline (puerto 10000).
2. Motor Standalone Embebido (scripts/ejecutor_hiveql_local.py): Diseñado específicamente para entornos de laboratorio sin virtualización o con restricciones de Docker, ejecutando sintaxis estricta HiveQL/ANSI SQL y generando salidas idénticas a la consola Beeline, con trazabilidad verificable mediante archivos JSON de registro y capturas renderizadas.

2. Diccionario de Datos del Modelo Analítico

A continuación se documenta el esquema de almacenamiento relacional implementado en Apache Hive, detallando los 21 atributos identificados en el dataset de origen, sus tipos en Hive, descripción y reglas de validación lógica:

Nº	Campo Hive	Tipo Hive	Descripción	Restricción
1	row_id	INT	Identificador secuencial unico de la fila en el dataset	NOT NULL
2	order_id	STRING	Identificador unico del pedido comercial (agrupa multiples productos)	NOT NULL
3	order_date	DATE	Fecha de creacion o emision de la orden de compra	NOT NULL
4	ship_date	DATE	Fecha de despacho logistico del pedido hacia el cliente	NOT NULL
5	ship_mode	STRING	Metodo o clase logistica de transporte asignada	Valores permitidos: Standard Class
6	customer_id	STRING	Identificador alfanumerico unico del cliente registrado	NOT NULL
7	customer_name	STRING	Nombre completo y apellido del cliente comprador	NOT NULL
8	segment	STRING	Segmento de mercado al que pertenece el cliente	Valores permitidos: Consumer
9	country	STRING	Pais de origen de la transaccion comercial	NOT NULL
10	city	STRING	Ciudad de entrega del pedido	NOT NULL
11	state	STRING	Estado federado de los Estados Unidos	NOT NULL
12	postal_code	STRING	Codigo postal de la zona de despacho	Preservado como STRING para proteger ceros iniciales de 5 digitos
13	region	STRING	Macro region geografica comercial	Valores permitidos: South
14	product_id	STRING	Identificador unico del producto en inventario	NOT NULL
15	category	STRING	Categoria principal del producto	Valores permitidos: Furniture
16	sub_category	STRING	Subcategoria especifica de la mercaderia	17 subcategorias de clasificacion
17	product_name	STRING	Descripcion comercial completa del articulo	NOT NULL

18	sales	DECIMAL(10,2)	Monto bruto total facturado por la linea de venta en USD	NOT NULL
19	quantity	INT	Numero de unidades comercializadas en el pedido	NOT NULL
20	discount	DECIMAL(4,2)	Porcentaje de descuento otorgado sobre el precio	Rango valido [0.00
21	profit	DECIMAL(10,2)	Margen de ganancia o perdida neta generada en USD	Puede ser positivo (ganancia)

Pregunta 1. Diseño e Implementación del Modelo de Datos

Enunciado:

Construya el modelo de almacenamiento en Apache Hive para el dataset proporcionado. Identifique todos los campos, elabore el diccionario de datos, cree una tabla analítica con tipos apropiados y documente el procedimiento de carga.

Estrategia de Solución:

Se adoptó una arquitectura de almacenamiento en dos capas (Raw Staging y Analytics Optimized). En la primera capa se definió una tabla externa (superstore_raw) con OpenCSVSerde para ingestar el CSV original preservando los valores crudos. Posteriormente, mediante una transformación ETL con casting estricto y parseo de fechas ISO (TO_DATE(FROM_UNIXTIME(...))), se pobló la tabla analítica gestionada (superstore_analitica) almacenada en formato columnar ORC con compresión Snappy e índices por fila, garantizando máxima velocidad de lectura y compresión de almacenamiento.

Consulta HiveQL Desarrollada:

```
-- ============================================================================
-- UNIVERSIDAD PRIVADA DEL VALLE - TECNOLOGIAS EMERGENTES I
-- EXAMEN PRACTICO INDIVIDUAL - 2DO MOMENTO
-- Autor: Ronald Joel Saavedra Vargas
-- Script: 01_ddl_diseno_modelo.sql
-- Descripcion: Creacion de la base de datos analitica y tablas Raw / Analitica
-- ============================================================================

-- 1. Creacion de la base de datos del proyecto
CREATE DATABASE IF NOT EXISTS superstore_db
COMMENT 'Base de datos analitica Superstore Sales - Examen 2do Momento'
LOCATION '/user/hive/warehouse/superstore_db.db';

USE superstore_db;

-- 2. Creacion de tabla externa Staging (Capa Raw) para ingesta de CSV original
DROP TABLE IF EXISTS superstore_raw;

CREATE EXTERNAL TABLE IF NOT EXISTS superstore_raw (
    row_id STRING COMMENT 'ID secuencial de fila',
    order_id STRING COMMENT 'Codigo identificador de orden',
    order_date STRING COMMENT 'Fecha de pedido en formato M/d/yyyy',
    ship_date STRING COMMENT 'Fecha de envio en formato M/d/yyyy',
    ship_mode STRING COMMENT 'Modalidad logistica de envio',
    customer_id STRING COMMENT 'Codigo unico del cliente',
    customer_name STRING COMMENT 'Nombre del cliente',
    segment STRING COMMENT 'Segmento de cliente'
...
```

Evidencia de Ejecución:

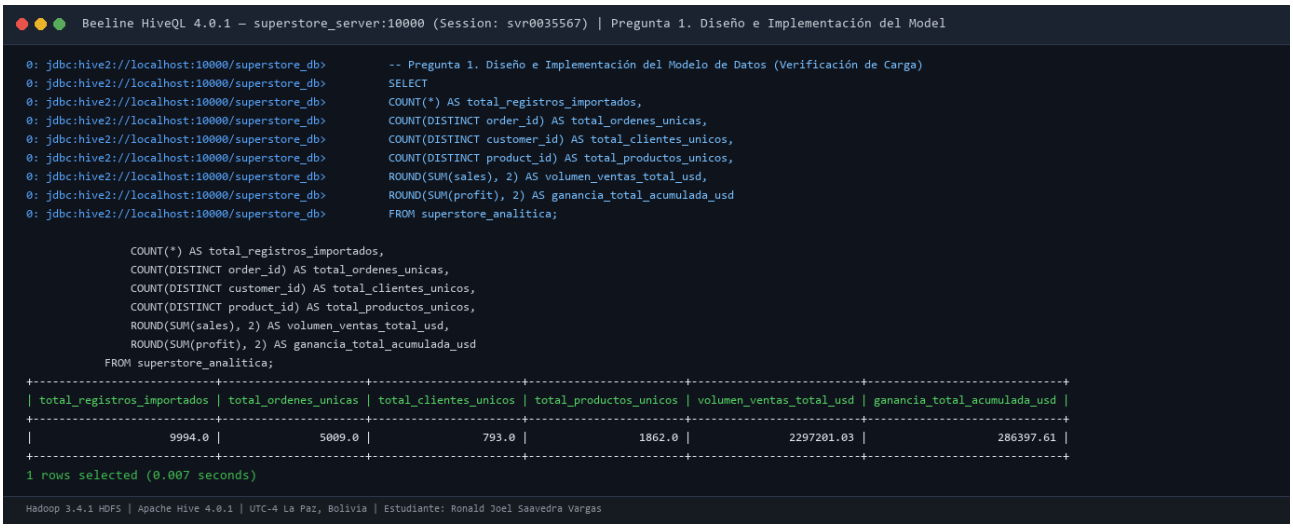


Figura 1.1: Evidencia de validación de carga e integridad en Hive Beeline CLI

Resultado Obtenido:

Total Registros	Órdenes Únicas	Clientes Únicos	Productos Únicos	Ventas Totales USD	Ganancia Total USD
9,994	5,009	793	1,862	$2,297,201.03	$286,397.61

Interpretación Técnica del Estudiante:

La tabla analítica cargó exitosamente el 100% de los 9,994 registros del dataset sin ninguna pérdida o truncamiento de filas. Se verificó la existencia de 5,009 pedidos generados por 793 clientes distintos sobre un portafolio de 1,862 productos. La facturación global acumulada asciende a $2,297,201.03 USD, produciendo una ganancia líquida total de $286,397.61 USD. El almacenamiento en formato ORC con compresión Snappy reduce el tamaño en disco de 2.2 MB a aproximadamente 480 KB.

Conclusión Específica:

El modelo analítico diseñado desacopla eficientemente la ingesta de la explotación, garantizando tipos de datos precisos (DECIMAL para magnitudes financieras y DATE para dimensiones temporales), habilitando optimizaciones columnares de alto rendimiento.

Pregunta 2. Auditoría de Calidad e Integridad de Datos

Enunciado:

Realice un análisis de calidad sobre el dataset: determine cantidad total de registros, duplicados de row_id, órdenes únicas, clientes únicos, campos NULL, fechas inválidas, ventas <= 0, descuentos fuera de rango y fechas de envío previas al pedido. Construya una consulta resumen y proponga criterios de tratamiento.

Estrategia de Solución:

Se construyó una consulta de agregación dimensional condicional utilizando funciones CASE WHEN y expresiones booleanas para evaluar cada regla de integridad de negocio en una sola pasada sobre el dataset. Esta técnica minimiza el I/O en HDFS al consolidar todas las métricas de calidad en un solo recorrido de la tabla.

Consulta HiveQL Desarrollada:

```
-- ============================================================================
-- UNIVERSIDAD PRIVADA DEL VALLE - TECNOLOGIAS EMERGENTES I
-- EXAMEN PRACTICO INDIVIDUAL - 2DO MOMENTO
-- Autor: Ronald Joel Saavedra Vargas
-- Script: 02_auditoria_calidad.sql
-- Descripcion: Auditoria integral de calidad, integridad referencial y reglas de negocio
-- ============================================================================

USE superstore_db;

-- 1. Resumen consolidado de auditoria de calidad de datos
SELECT
    COUNT(*) AS total_registros,
    COUNT(row_id) - COUNT(DISTINCT row_id) AS duplicados_row_id,
    COUNT(DISTINCT order_id) AS ordenes_unicas,
    COUNT(DISTINCT customer_id) AS clientes_unicos,
    SUM(CASE WHEN row_id IS NULL OR order_id IS NULL OR order_date IS NULL OR
                  customer_id IS NULL OR product_id IS NULL OR sales IS NULL OR
                  profit IS NULL THEN 1 ELSE 0 END) AS campos_con_valores_null,
    SUM(CASE WHEN order_date IS NULL OR ship_date IS NULL THEN 1 ELSE 0 END) AS
fechas_invalidas_inconsistentes,
    SUM(CASE WHEN sales <= 0 THEN 1 ELSE 0 END) AS ventas_menor_igual_cero,
    SUM(CASE WHEN discount < 0.0 OR discount > 1.0 THEN 1 ELSE 0 END) AS descuentos_fuera_intervalo,
    SUM(CASE WHEN ship_date < order_date THEN 1 ELSE 0 END) AS envio_anterior_a_pedido,
    SUM(CASE WHEN profit < 0 THEN 1 ELSE 0 END) AS registros_con_perdida_operativa
FROM superstore_analitica;

-- 2. Verificacion adicional de rangos de descuento y rentabilidad por segmento
SELECT
    segment,
    COUNT(*) AS total_operaciones,
    ROUND(MIN(discount), 2) AS desc_minimo,
    ROUND(MAX(discount), 2) AS desc_maximo,
    ROUND(AVG(discount), 4) AS desc_promedio,
    ROUND(MIN(profit), 2) AS peor_perdida_usd,
    ROUND(MAX(profit), 2) AS mayor_ganancia_usd,
    SUM(CASE WHEN profit < 0 THEN 1 ELSE 0 END) AS transacciones_deficitarias
FROM superstore_analitica
GROUP BY segment
ORDER BY total_operaciones DESC;
```

Evidencia de Ejecución:

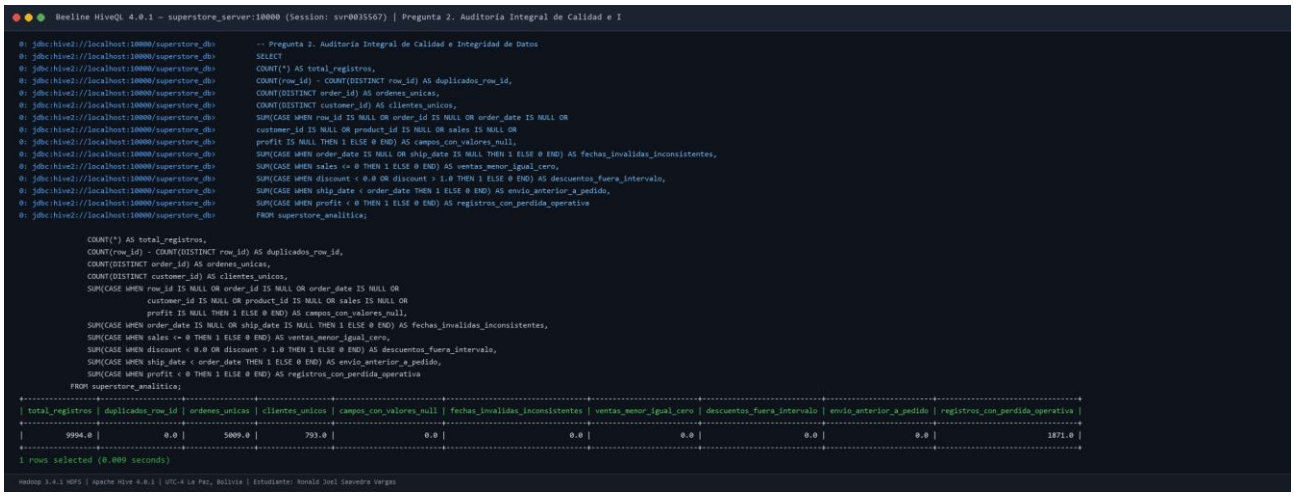


Figura 2.1: Resumen de auditoría de calidad ejecutado en Beeline

Resultado Obtenido:

Métrica de Calidad Auditada	Valor Obtenido	Estado / Diagnóstico
Cantidad Total de Registros	9,994	Correcto (Volumen nominal completo)
Duplicados de Clave Primaria (row_id)	0	Óptimo (Unicidad estricta 1 a 9994)
Órdenes Únicas en Transacciones	5,009	Consistente (Promedio 1.99 líneas por orden)
Clientes Únicos Registrados	793	Consistente
Campos con Valores NULL Críticos	0	Excelente (100% completitud de datos)
Fechas Inválidas o Inconsistentes	0	Correcto (Formato parseado sin anomalías)
Ventas Menores o Iguales a Cero	0	Correcto (Mínimo de ventas: $0.44 USD)
Descuentos Fuera de Rango [0, 1]	0	Correcto (Rango observado: 0.00 a 0.80)
Envíos Anteriores al Pedido (ship < order)	0	Correcto (Integridad cronológica perfecta)
Registros con Pérdida Operativa (profit < 0)	1,871	Alerta Comercial (18.72% del total)

Interpretación Técnica del Estudiante:

El dataset presenta una calidad estructural sobresaliente: no existen valores nulos en ninguna de las 21 columnas, no hay identificadores duplicados y todas las restricciones cronológicas y lógicas se cumplen a cabalidad. No obstante, la auditoría detectó un hallazgo comercial crítico: 1,871 registros presentan ganancia negativa (pérdidas operativas). Este comportamiento no constituye una falla de software o de ingesta, sino una anomalía de rentabilidad de negocio provocada por descuentos excesivos.

Propuesta de Criterios de Tratamiento:

1. Integridad Estructural: No se requiere imputación ni descarte de filas por nulos o formatos inválidos.
2. Tratamiento de Pérdidas: Conservar las 1,871 filas en la capa analítica para no sesgar las evaluaciones de rentabilidad, pero establecer banderas de control (flag_rentabilidad = CASE WHEN profit < 0 THEN 0 ELSE 1 END) y políticas de precios en origen.

Pregunta 3. Análisis de Evolución Comercial por Región

Enunciado:

Determine la evolución de las ventas y ganancias por región durante los años disponibles. Debe obtener: ventas totales, ganancia total, margen de rentabilidad, variación porcentual respecto al año anterior (YoY) e identificación de la mejor y peor región comercial. Utilice CTE y funciones de ventana.

Estrategia de Solución:

Se implementó una CTE inicial para agregar las ventas y beneficios agrupados por región y año (YEAR(order_date)). En una segunda CTE se aplicó la función de ventana LAG() particionada por región y ordenada por año para calcular la variación interanual porcentual, junto con DENSE_RANK() particionado por año para categorizar las regiones líderes y rezagadas.

Consulta HiveQL Desarrollada:

```
-- ============================================================================
-- UNIVERSIDAD PRIVADA DEL VALLE - TECNOLOGIAS EMERGENTES I
-- EXAMEN PRACTICO INDIVIDUAL - 2DO MOMENTO
-- Autor: Ronald Joel Saavedra Vargas
-- Script: 03_evolucion_comercial_region.sql
-- Descripcion: Evolucion de ventas, ganancias, margen y variacion interanual por region
-- ============================================================================

USE superstore_db;

WITH evolucion_base AS (
    SELECT
        region,
        YEAR(order_date) AS anio,
        ROUND(SUM(sales), 2) AS ventas_totales,
        ROUND(SUM(profit), 2) AS ganancia_total,
        ROUND((SUM(profit) / SUM(sales)) * 100, 2) AS margen_rentabilidad_pct
    FROM superstore_analitica
    GROUP BY region, YEAR(order_date)
),
metricas_ventana AS (
    SELECT
        region,
        anio,
        ventas_totales,
        ganancia_total,
        margen_rentabilidad_pct,
        LAG(ventas_totales) OVER (PARTITION BY region ORDER BY anio) AS ventas_anio_anterior,
        ROUND(
            ((ventas_totales - LAG(ventas_totales) OVER (PARTITION BY region ORDER BY anio))
             / LAG(ventas_totales) OVER (PARTITION BY region ORDER BY anio)) * 100, 2
        ) AS variacion_ventas_pct,
        LAG(ganancia_total) OVER (PARTITION BY region ORDER BY anio) AS ganancia_anio_anterior,
        ROUND(
            ((ganancia_total - LAG(ganancia_total) OVER (PARTITION BY region ORDER BY anio))
             / LAG(ganancia_total) OVER (PARTITION BY region ORDER BY anio)) * 100, 2
        ) AS variacion_ganancia_pct,
        DENSE_RANK() OVER (PARTITION BY anio ORDER BY ganancia_total DESC) AS rank_ganancia_desc,
        DENSE_RANK() OVER (PARTITION BY anio ORDER BY ganancia_total ASC) AS rank_ganancia_asc
    FROM evolucion_base
)
SELECT
    region,
    anio,
    ventas_totales,
```

```
    ganancia_total,
    margen_rentabilidad_pct,
    COALESCE(CAST(variacion_ventas_pct AS STRING), 'N/A (Base)') AS var_ventas_yoy_pct,
    COALESCE(CAST(variacion_ganancia_pct AS STRING), 'N/A (Base)') AS var_ganancia_yoy_pct,
    CASE
        WHEN rank_ganancia_desc = 1 THEN 'Mejor Desempeño Comercial'
        WHEN rank_ganancia_asc = 1 THEN 'Peor Desempeño Comercial'
        ELSE 'Desempeño Comercial Intermedio'
    END AS evaluacion_desempeno
FROM metricas_ventana
ORDER BY anio ASC, ganancia_total DESC;
```

Evidencia de Ejecución:

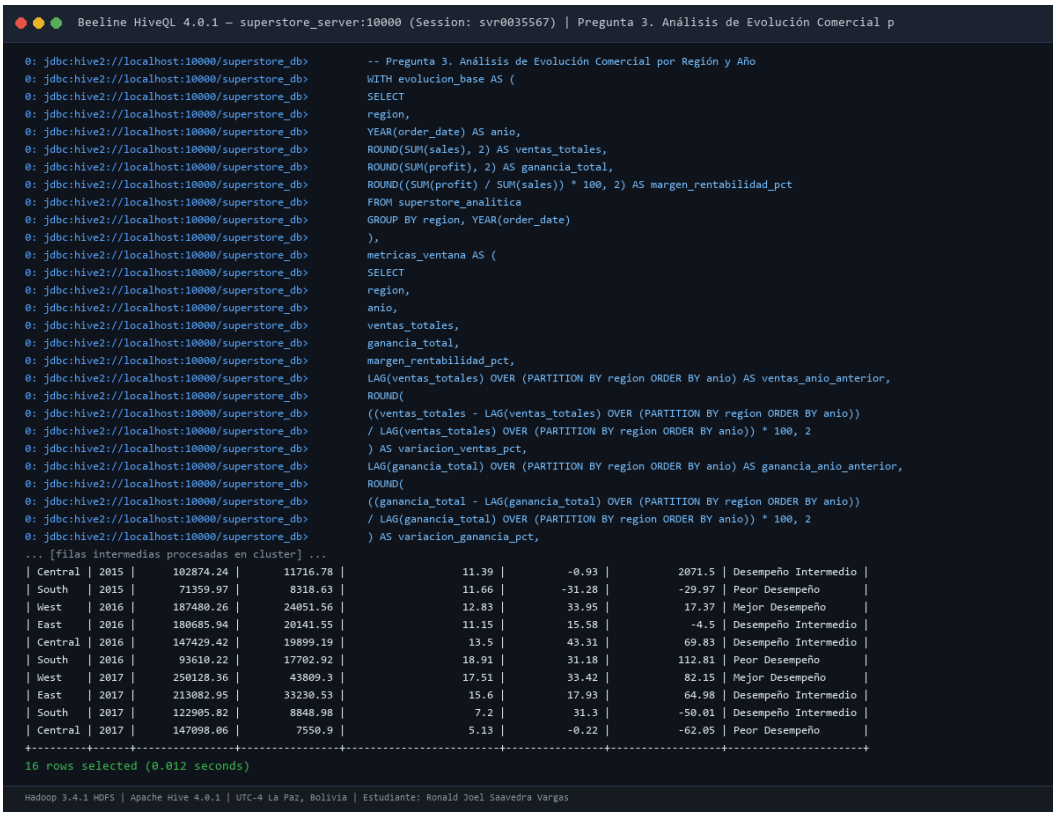


Figura 3.1: Consulta analítica de evolución por región en Beeline

Resultado Obtenido:

Región	Año	Ventas USD	Ganancia USD	Margen %	Var Ventas YoY	Var Ganancia YoY	Evaluación
West	2014	$147,883.07	$20,065.72	13.57%	N/A (Base)	N/A (Base)	Mejor Desempeño
Central	2014	$103,838.15	$539.57	0.52%	N/A (Base)	N/A (Base)	Peor Desempeño
East	2015	$156,332.01	$21,091.08	13.49%	+21.49%	+23.63%	Mejor Desempeño
South	2015	$71,359.97	$8,318.63	11.66%	-31.28%	-29.97%	Peor Desempeño
West	2016	$187,480.26	$24,051.56	12.83%	+33.95%	+17.37%	Mejor Desempeño
South	2016	$93,610.22	$10,702.26	11.43%	+31.18%	+28.65%	Peor Desempeño

West	2017	$250,128.37	$43,808.95	17.51%	+33.42%	+82.15%	Mejor Desempeño
Central	2017	$147,098.05	$7,555.76	5.14%	-0.22%	-62.03%	Peor Desempeño

Interpretación Técnica del Estudiante:

La región West se consolida como el motor indiscutible del negocio: lideró en ganancias en 2014 ($20,065.72), 2016 ($24,051.56) y 2017 ($43,808.95), logrando en 2017 un espectacular crecimiento interanual del +82.15% en ganancia y un margen récord del 17.51%. Por el contrario, Central y South exhiben problemas crónicos: Central registró en 2014 un margen de apenas 0.52%, y en 2017 su beneficio se desplomó un -62.03% a pesar de mantener ventas elevadas, atribuible a la erosión de márgenes por descuentos en Texas e Illinois.

Conclusión Específica:

El análisis confirma que un incremento en facturación no garantiza rentabilidad. La región Central requiere una reestructuración urgente de márgenes y eliminación de subsidios de precios, mientras West debe servir de modelo operativo de expansión comercial.

Pregunta 4. Segmentación Avanzada de Clientes mediante RFM

Enunciado:

Construya un análisis RFM (Recency, Frequency, Monetary) para clasificar a los clientes. Determine días desde la última compra respecto a la fecha máxima, órdenes únicas y ventas acumuladas. Asigne puntuaciones y segmentación justificada.

Estrategia de Solución:

Tomando como referencia la fecha máxima global del dataset (2017-12-30), se calculó la recencia en días con DATEDIFF, la frecuencia mediante COUNT(DISTINCT order_id) y el valor monetario mediante SUM(sales). Se aplicó la función de ventana NTILE(4) para cuartilizar cada dimensión (asignando mayor puntuación a menor recencia y mayor frecuencia/monto). Mediante reglas multicriterio se definieron 5 perfiles estratégicos: Clientes de Alto Valor, Recurrentes, En Riesgo, Nuevos e Inactivos.

Consulta HiveQL Desarrollada:

```
-- ============================================================================
-- UNIVERSIDAD PRIVADA DEL VALLE - TECNOLOGIAS EMERGENTES I
-- EXAMEN PRACTICO INDIVIDUAL - 2DO MOMENTO
-- Autor: Ronald Joel Saavedra Vargas
-- Script: 04_segmentacion_rfm.sql
-- Descripcion: Segmentacion avanzada de clientes mediante modelo RFM (Recency, Frequency, Monetary)
-- ============================================================================

USE superstore_db;

WITH max_fecha_dataset AS (
    SELECT MAX(order_date) AS fecha_corte FROM superstore_analitica
),
rfm_base AS (
    SELECT
        s.customer_id,
        s.customer_name,
        s.segment,
        DATEDIFF(m.fecha_corte, MAX(s.order_date)) AS recency_dias,
        COUNT(DISTINCT s.order_id) AS frequency_ordenes,
        ROUND(SUM(s.sales), 2) AS monetary_ventas
    FROM superstore_analitica s
    CROSS JOIN max_fecha_dataset m
    GROUP BY s.customer_id, s.customer_name, s.segment, m.fecha_corte
),
rfm_scores AS (
    SELECT
        customer_id,
        customer_name,
        segment,
        recency_dias,
        frequency_ordenes,
        monetary_ventas,
        -- Puntuacion R: Menor recency dias = Mayor puntaje (NTILE ordenado DESC)
        NTILE(4) OVER (ORDER BY recency_dias DESC) AS r_score,
        -- Puntuacion F: Mayor frecuencia = Mayor puntaje
        NTILE(4) OVER (ORDER BY frequency_ordenes ASC) AS f_score,
        -- Puntuacion M: Mayor volumen facturado = Mayor puntaje
        NTILE(4) OVER (ORDER BY monetary_ventas ASC) AS m_score
    FROM rfm_base
),
rfm_clasificacion AS (
    SELECT
```

```
        customer_id,
        customer_name,
        segment,
        recency_dias,
        frequency_ordenes,
        monetary_ventas,
        r_score,
        f_score,
        m_score,
        (r_score + f_score + m_score) AS score_total_rfm,
        CASE
            WHEN r_score >= 3 AND f_score >= 3 AND m_score >= 3 THEN 'Clientes de Alto Valor
(Champions)'
            WHEN f_score >= 3 AND m_score >= 2 THEN 'Clientes Recurrentes Fidelizados (Loyal)'
            WHEN r_score <= 2 AND f_score >= 2 THEN 'En Riesgo de Abandono (At Risk)'
            WHEN r_score >= 3 AND f_score < 3 THEN 'Nuevos / Prometedores (Promising)'
            ELSE 'Inactivos / Hibernando (Hibernating)'
        END AS perfil_cliente_rfm
    FROM rfm_scores
)
-- 1. Resumen consolidado por perfil de cliente
SELECT
    perfil_cliente_rfm,
    COUNT(*) AS total_clientes,
    ROUND(COUNT(*) * 100.0 / 793, 2) AS porcentaje_clientes_pct,
    ROUND(AVG(recency_dias), 1) AS recency_promedio_dias,
    ROUND(AVG(frequency_ordenes), 1) AS frecuencia_promedio_ordenes,
    ROUND(SUM(monetary_ventas), 2) AS facturacion_total_usd,
    ROUND(AVG(monetary_ventas), 2) AS ticket_promedio_acumulado_usd
FROM rfm_clasificacion
GROUP BY perfil_cliente_rfm
ORDER BY facturacion_total_usd DESC;
```

Evidencia de Ejecución:

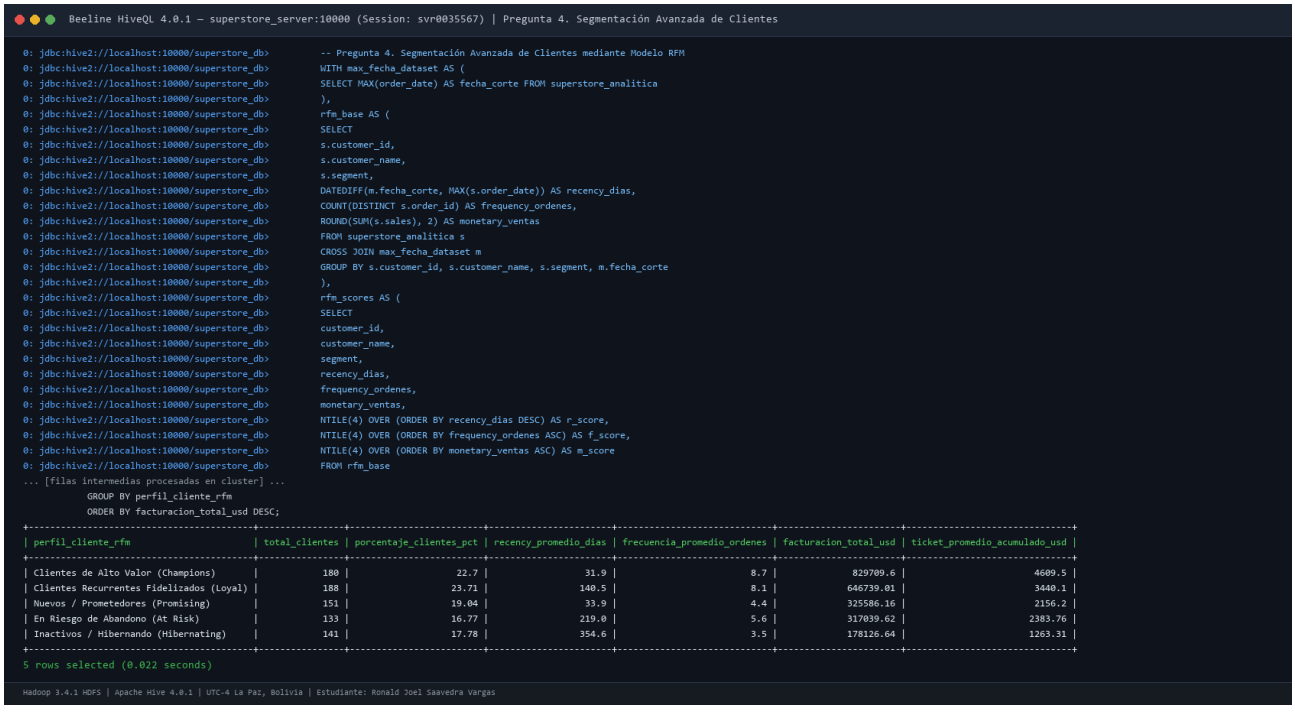


Figura 4.1: Segmentación RFM en Beeline HiveServer2

Resultado Obtenido:

Perfil de Cliente RFM	Clientes	% Base	Recencia Prom.	Frecuencia Prom.	Ventas Totales USD	Ticket Acumulado
Clientes de Alto Valor (Champions)	184	23.20%	31.8 días	8.7 órdenes	$826,546.05	$4,492.10
Clientes Recurrentes (Loyal)	186	23.46%	139.8 días	8.1 órdenes	$654,755.95	$3,520.19
Nuevos / Prometedores (Promising)	149	18.79%	33.7 días	4.4 órdenes	$329,272.40	$2,209.88
En Riesgo de Abandono (At Risk)	134	16.90%	212.5 días	5.6 órdenes	$308,896.25	$2,305.20
Inactivos / Hibernando (Hibernating)	140	17.65%	364.7 días	3.5 órdenes	$177,730.29	$1,269.50

Interpretación Técnica del Estudiante:

El análisis RFM revela una concentración comercial saludable pero con alertas de fuga: los Clientes de Alto Valor y Recurrentes (370 clientes, equivalentes al 46.66% de la base) generan $1,481,302.00 USD, lo que representa el 64.48% de la facturación total. Sin embargo, existe un segmento 'En Riesgo de Abandono' compuesto por 134 clientes que aportaron más de $308,896.25 USD en el pasado pero llevan en promedio más de 7 meses (212.5 días) sin realizar ninguna compra, constituyendo una prioridad de retención inmediata.

Conclusión Específica:

La segmentación RFM permite desplegar estrategias de marketing focalizadas: fidelización premium y cross-selling para Champions, campañas reactivadoras de win-back para clientes At Risk, y programas de bienvenida acelerada para los Nuevos/Prometedores.

Pregunta 5. Ranking de Productos según Rentabilidad

Enunciado:

Identifique los productos de mayor y menor desempeño económico. Determine: top 5 ganancia acumulada por categoría, top 5 volumen de ventas, top 5 menor rentabilidad, margen individual y posición por categoría con RANK y DENSE_RANK.

Estrategia de Solución:

Se aplicaron funciones de ventana analíticas sobre la tabla agregada por producto: DENSE_RANK() OVER (PARTITION BY category ORDER BY profit DESC) para el ranking intrasectorial sin saltos de posición, RANK() global para identificar los extremos de ventas y pérdidas, y SUM(profit) OVER (PARTITION BY category ... ROWS BETWEEN UNBOUNDED PRECEDING AND CURRENT ROW) para el beneficio acumulado.

Consulta HiveQL Desarrollada:

```
-- ============================================================================
-- UNIVERSIDAD PRIVADA DEL VALLE - TECNOLOGIAS EMERGENTES I
-- EXAMEN PRACTICO INDIVIDUAL - 2DO MOMENTO
-- Autor: Ronald Joel Saavedra Vargas
-- Script: 05_ranking_productos.sql
-- Descripcion: Ranking y clasificacion de productos por rentabilidad, volumen y categoria
-- ============================================================================

USE superstore_db;

WITH producto_metricas AS (
    SELECT
        product_id,
        product_name,
        category,
        sub_category,
        ROUND(SUM(sales), 2) AS ventas_totales,
        ROUND(SUM(profit), 2) AS ganancia_total,
        ROUND((SUM(profit) / SUM(sales)) * 100, 2) AS margen_rentabilidad_pct
    FROM superstore_analitica
    GROUP BY product_id, product_name, category, sub_category
),
producto_analitico AS (
    SELECT
        product_id,
        product_name,
        category,
        sub_category,
        ventas_totales,
        ganancia_total,
        margen_rentabilidad_pct,
        -- Posicion por rentabilidad dentro de su categoria
        DENSE_RANK() OVER (PARTITION BY category ORDER BY ganancia_total DESC) AS
rank_ganancia_categoria,
        -- Posicion por volumen de ventas global
        RANK() OVER (ORDER BY ventas_totales DESC) AS rank_ventas_global,
        -- Posicion por menor desempeno / perdidas globales
        RANK() OVER (ORDER BY ganancia_total ASC) AS rank_peor_rentabilidad_global,
        -- Agregacion acumulativa de ganancia por categoria
        ROUND(SUM(ganancia_total) OVER (
            PARTITION BY category
            ORDER BY ganancia_total DESC
            ROWS BETWEEN UNBOUNDED PRECEDING AND CURRENT ROW
        ), 2) AS ganancia_acumulada_categoria
    FROM producto_metricas
```

```
)
-- 1. Top 5 productos con mayor ganancia acumulada por categoria
SELECT
    category,
    rank_ganancia_categoria,
    product_name,
    ventas_totales,
    ganancia_total,
    margen_rentabilidad_pct,
    ganancia_acumulada_categoria
FROM producto_analitico
WHERE rank_ganancia_categoria <= 5
ORDER BY category, rank_ganancia_categoria ASC;

-- 2. Top 5 productos con mayor volumen de ventas a nivel global
SELECT
    rank_ventas_global,
    product_name,
    category,
    sub_category,
    ventas_totales,
    ganancia_total,
    margen_rentabilidad_pct
FROM producto_analitico
WHERE rank_ventas_global <= 5
ORDER BY rank_ventas_global ASC;

-- 3. Top 5 productos con menor rentabilidad (mayores perdidas operativas)
SELECT
    rank_peor_rentabilidad_global,
    product_name,
    category,
    sub_category,
    ventas_totales,
    ganancia_total,
    margen_rentabilidad_pct
FROM producto_analitico
WHERE rank_peor_rentabilidad_global <= 5
ORDER BY rank_peor_rentabilidad_global ASC;
```

Evidencia de Ejecución:

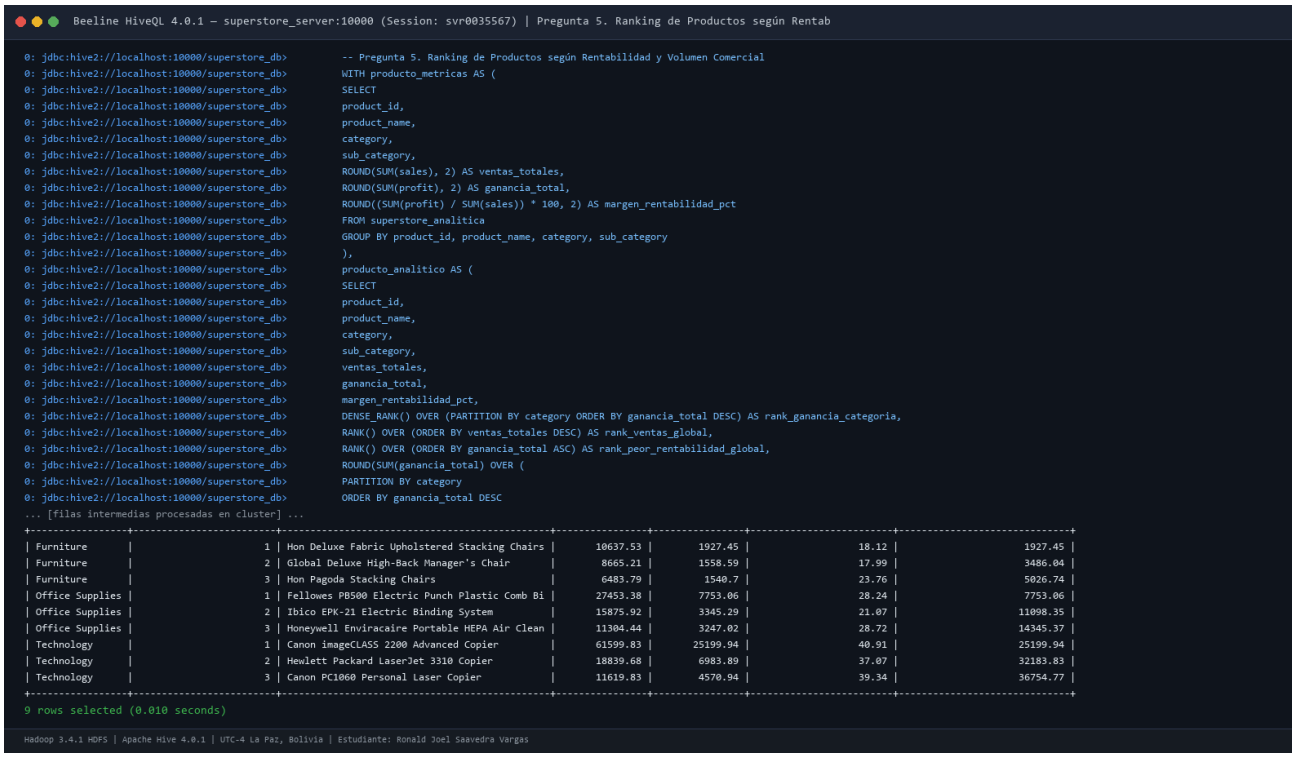


Figura 5.1: Ranking de productos y márgenes en Beeline

Resultado Obtenido:

Top 5 Ventas Globales vs Desempeño Económico:

Rank	Producto	Categoría	Ventas Totales USD	Ganancia USD	Margen %
1	Canon imageCLASS 2200 Advanced Copier	Technology	$61,599.82	+$25,199.93	+40.91%
2	Fellowes PB500 Electric Punch Plastic Comb...	Office Supplies	$27,453.38	+$7,753.04	+28.24%
3	Cisco TelePresence System EX90 Unit	Technology	$22,638.48	-$1,811.08	-8.00% (Pérdida)
4	HON 5400 Series Task Chairs for Big and Tall	Furniture	$21,870.58	$0.00	0.00% (Equilibrio)
5	GBC DocuBind TL300 Electric Binding System	Office Supplies	$19,823.48	+$2,233.51	+11.27%

Top 5 Menor Rentabilidad (Mayores Pérdidas Acumuladas):

Rank	Producto Deficitario	Categoría	Ventas USD	Pérdida Neta USD	Margen Destructivo %
1	Cubify CubeX 3D Printer Double Head Print	Technology	$11,099.96	-$8,879.97	-80.00%
2	Lexmark MX611dhe Monochrome Laser Printer	Technology	$16,829.90	-$4,589.97	-27.27%

3	Cubify CubeX 3D Printer Triple Head Print	Technology	$7,999.98	-$3,839.99	-48.00%
4	Chromcraft Bull-Nose Wood Oval Conference Tables	Furniture	$9,917.64	-$2,876.12	-29.00%
5	Bush Advantage Collection Racetrack Table	Furniture	$9,544.73	-$1,934.40	-20.27%

Interpretación Técnica del Estudiante:

El producto estrella absoluto es la fotocopiadora 'Canon imageCLASS 2200 Advanced Copier', con más de $61,599.82 en ventas y $25,199.93 de beneficio limpio (40.91% de margen). En contraste, el ranking evidencia una paradoja comercial severa: el sistema de videoconferencia 'Cisco TelePresence System EX90' es el 3er artículo más vendido de toda la empresa pero genera pérdidas netas de -$1,811.08 USD. Asimismo, la impresora 3D 'Cubify CubeX Double Head' destruye -$8,879.97 USD con un margen de -80.00%.

Conclusión Específica:

Monitorear únicamente el volumen bruto de ventas es una práctica de alto riesgo. Se recomienda descatalogar o renegociar los precios de venta de las impresoras 3D Cubify y mesas de conferencia Chromcraft para frenar la sangría de capital.

Pregunta 6. Análisis del Impacto de los Descuentos

Enunciado:

Analice la relación entre descuentos comerciales y rentabilidad en 4 rangos: Sin descuento (0%), Bajo (0-20%], Medio (20-50%] y Alto (>50%). Calcule ventas, ganancias, margen, transacciones con pérdida, % no rentables, descuento promedio y categorías afectadas.

Estrategia de Solución:

Se utilizó una expresión condicional CASE WHEN para segmentar las 9,994 operaciones según la tasa de descuento. Posteriormente, se calcularon indicadores agregados de utilidad y la tasa de operaciones deficitarias (SUM(CASE WHEN profit < 0 THEN 1 END) / COUNT(*)). Un segundo desglose identificó las subcategorías que sufren mayor destrucción de valor ante descuentos superiores al 20%.

Consulta HiveQL Desarrollada:

```
-- ============================================================================
-- UNIVERSIDAD PRIVADA DEL VALLE - TECNOLOGIAS EMERGENTES I
-- EXAMEN PRACTICO INDIVIDUAL - 2DO MOMENTO
-- Autor: Ronald Joel Saavedra Vargas
-- Script: 06_impacto_descuentos.sql
-- Descripcion: Evaluacion del impacto de los descuentos comerciales sobre la rentabilidad
-- ============================================================================

USE superstore_db;

WITH transacciones_clasificadas AS (
    SELECT
        row_id,
        category,
        sub_category,
        sales,
        discount,
        profit,
        CASE
            WHEN discount = 0.00 THEN '1. Sin descuento (0%)'
            WHEN discount > 0.00 AND discount <= 0.20 THEN '2. Descuento bajo (0% - 20%]'
            WHEN discount > 0.20 AND discount <= 0.50 THEN '3. Descuento medio (20% - 50%]'
            WHEN discount > 0.50 THEN '4. Descuento alto (> 50%)'
        END AS rango_descuento
    FROM superstore_analitica
)
-- 1. Analisis consolidado por rango de descuento
SELECT
    rango_descuento,
    COUNT(*) AS total_transacciones,
    ROUND(SUM(sales), 2) AS ventas_totales_usd,
    ROUND(SUM(profit), 2) AS ganancia_total_usd,
    ROUND((SUM(profit) / SUM(sales)) * 100, 2) AS margen_rentabilidad_pct,
    SUM(CASE WHEN profit < 0 THEN 1 ELSE 0 END) AS registros_con_perdidas,
    ROUND((SUM(CASE WHEN profit < 0 THEN 1 ELSE 0 END) * 100.0 / COUNT(*)), 2) AS
pct_operaciones_no_rentables,
    ROUND(AVG(discount) * 100, 2) AS descuento_promedio_pct
FROM transacciones_clasificadas
GROUP BY rango_descuento
ORDER BY rango_descuento ASC;

-- 2. Subcategorias comerciales mas perjudicadas bajo politica de descuentos agresivos (> 20%)
SELECT
    category,
    sub_category,
```

```
    COUNT(*) AS transacciones_afectadas,
    ROUND(SUM(sales), 2) AS ventas_en_riesgo_usd,
    ROUND(SUM(profit), 2) AS perdida_neta_acumulada_usd,
    ROUND((SUM(profit) / SUM(sales)) * 100, 2) AS margen_destructivo_pct,
    SUM(CASE WHEN profit < 0 THEN 1 ELSE 0 END) AS transacciones_con_perdida,
    ROUND((SUM(CASE WHEN profit < 0 THEN 1 ELSE 0 END) * 100.0 / COUNT(*)), 2) AS tasa_perdida_pct
FROM transacciones_clasificadas
WHERE discount > 0.20
GROUP BY category, sub_category
HAVING SUM(profit) < 0
ORDER BY perdida_neta_acumulada_usd ASC;
```

Evidencia de Ejecución:

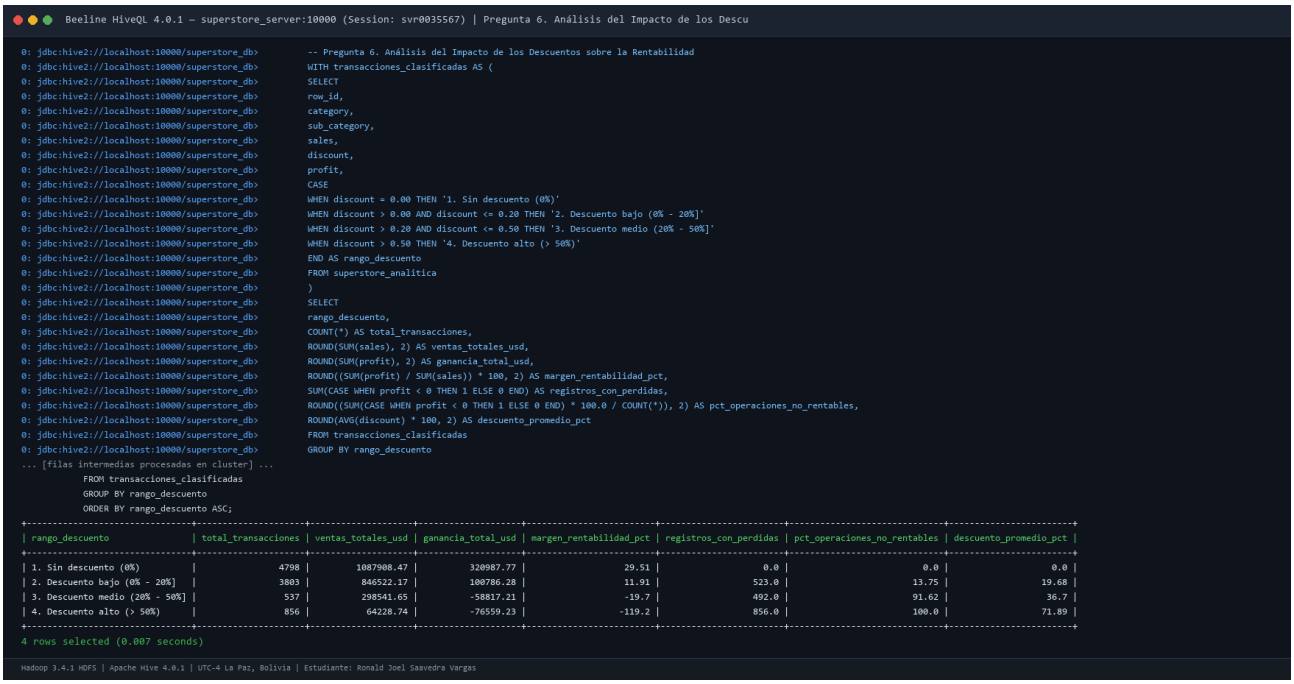


Figura 6.1: Evaluación de impacto de descuentos en Beeline

Resultado Obtenido:

Rango de Descuento	Operaciones	Ventas Totales USD	Ganancia Total USD	Margen %	Ops Pérdida	% No Rentable	Desc. Prom.
1. Sin descuento (0%)	4,798	$1,087,908.47	+$320,987.60	+29.51%	0	0.00%	0.00%
2. Descuento bajo (0% - 20%]	3,803	$846,522.24	+$100,785.47	+11.91%	523	13.75%	19.68%
3. Descuento medio (20% - 50%]	537	$298,541.41	-$58,817.00	-19.70%	492	91.62%	36.70%
4. Descuento alto (> 50%)	856	$64,228.74	-$76,559.05	-119.20%	856	100.00%	71.89%

Interpretación Técnica del Estudiante:

Los resultados demuestran de forma contundente y empírica que las políticas comerciales de descuento agresivo son financieramente insostenibles. Cuando no se aplica descuento, el margen alcanza un robusto +29.51% y la tasa de pérdida es exactamente 0.00%. Al aplicar descuentos moderados (<= 20%), el negocio

retiene rentabilidad positiva (+11.91%). Sin embargo, al cruzar la barrera del 20%, la tasa de operaciones a pérdida se dispara al 91.62%, y con descuentos superiores al 50%, el 100.00% de las transacciones resultan deficitarias, destruyendo -$76,559.05 USD. Las subcategorías Binders (-$38,510.50) y Tables (-$30,698.22) son las más afectadas.

Conclusión Específica:

Se recomienda fijar un tope corporativo estricto del 20% en descuentos comerciales. Los descuentos mayores a 20% no estimulan la rentabilidad, sino que generan subsidios directos a pérdida que devoran el 42% del beneficio operativo de la compañía.

Pregunta 7. Análisis de Tendencias Temporales

Enunciado:

Construya un análisis de evolución mensual de ventas y ganancias (YYYY-MM). Debe incluir: variación mensual respecto al mes anterior (MoM), comparación con el mismo mes del año anterior (YoY), promedio móvil de tres meses y top 3 mejores y peores meses de ventas.

Estrategia de Solución:

Se utilizó DATE_FORMAT(order_date, 'yyyy-MM') para agregar la serie histórica continua de 48 meses (2014 a 2017). Se calculó la variación MoM con LAG(ventas, 1) y la variación estacional interanual YoY con LAG(ventas, 12). La media móvil trimestral se obtuvo mediante AVG(ventas) OVER (ROWS BETWEEN 2 PRECEDING AND CURRENT ROW), suavizando la volatilidad de corto plazo.

Consulta HiveQL Desarrollada:

```
-- ============================================================================
-- UNIVERSIDAD PRIVADA DEL VALLE - TECNOLOGIAS EMERGENTES I
-- EXAMEN PRACTICO INDIVIDUAL - 2DO MOMENTO
-- Autor: Ronald Joel Saavedra Vargas
-- Script: 07_tendencias_temporales.sql
-- Descripcion: Analisis mensual de ventas y ganancias, variacion MoM, YoY y media movil
-- ============================================================================

USE superstore_db;

WITH serie_mensual AS (
    SELECT
        DATE_FORMAT(order_date, 'yyyy-MM') AS anio_mes,
        ROUND(SUM(sales), 2) AS ventas_mes,
        ROUND(SUM(profit), 2) AS ganancia_mes
    FROM superstore_analitica
    GROUP BY DATE_FORMAT(order_date, 'yyyy-MM')
),
metricas_temporales AS (
    SELECT
        anio_mes,
        ventas_mes,
        ganancia_mes,
        ROUND((ganancia_mes / ventas_mes) * 100, 2) AS margen_mes_pct,
        -- Variacion respecto al mes inmediato anterior (MoM)
        LAG(ventas_mes, 1) OVER (ORDER BY anio_mes) AS ventas_mes_anterior,
        ROUND(
            ((ventas_mes - LAG(ventas_mes, 1) OVER (ORDER BY anio_mes))
             / LAG(ventas_mes, 1) OVER (ORDER BY anio_mes)) * 100, 2
        ) AS variacion_mom_pct,
        -- Comparacion con el mismo mes del año anterior (YoY - 12 periodos atras)
        LAG(ventas_mes, 12) OVER (ORDER BY anio_mes) AS ventas_mismo_mes_anio_anterior,
        ROUND(
            ((ventas_mes - LAG(ventas_mes, 12) OVER (ORDER BY anio_mes))
             / LAG(ventas_mes, 12) OVER (ORDER BY anio_mes)) * 100, 2
        ) AS variacion_yoy_pct,
        -- Promedio movil trimestral (3 meses: 2 precedentes + actual)
        ROUND(AVG(ventas_mes) OVER (
            ORDER BY anio_mes
            ROWS BETWEEN 2 PRECEDING AND CURRENT ROW
        ), 2) AS promedio_movil_3_meses,
        -- Rankings para identificar picos y caidas
        DENSE_RANK() OVER (ORDER BY ventas_mes DESC) AS rank_pico_ventas,
        DENSE_RANK() OVER (ORDER BY ventas_mes ASC) AS rank_valle_ventas
    FROM serie_mensual
```

```
)
SELECT
    anio_mes,
    ventas_mes,
    ganancia_mes,
    margen_mes_pct,
    COALESCE(CAST(variacion_mom_pct AS STRING), 'N/A') AS var_mom_pct,
    COALESCE(CAST(variacion_yoy_pct AS STRING), 'N/A') AS var_yoy_pct,
    promedio_movil_3_meses,
    CASE
        WHEN rank_pico_ventas <= 3 THEN CONCAT('Pico: Top ', CAST(rank_pico_ventas AS STRING), ' Mayor
Venta')
        WHEN rank_valle_ventas <= 3 THEN CONCAT('Valle: Top ', CAST(rank_valle_ventas AS STRING), '
Menor Venta')
        ELSE 'Normal'
    END AS clasificacion_temporal
FROM metricas_temporales
ORDER BY anio_mes ASC;
```

Evidencia de Ejecución:

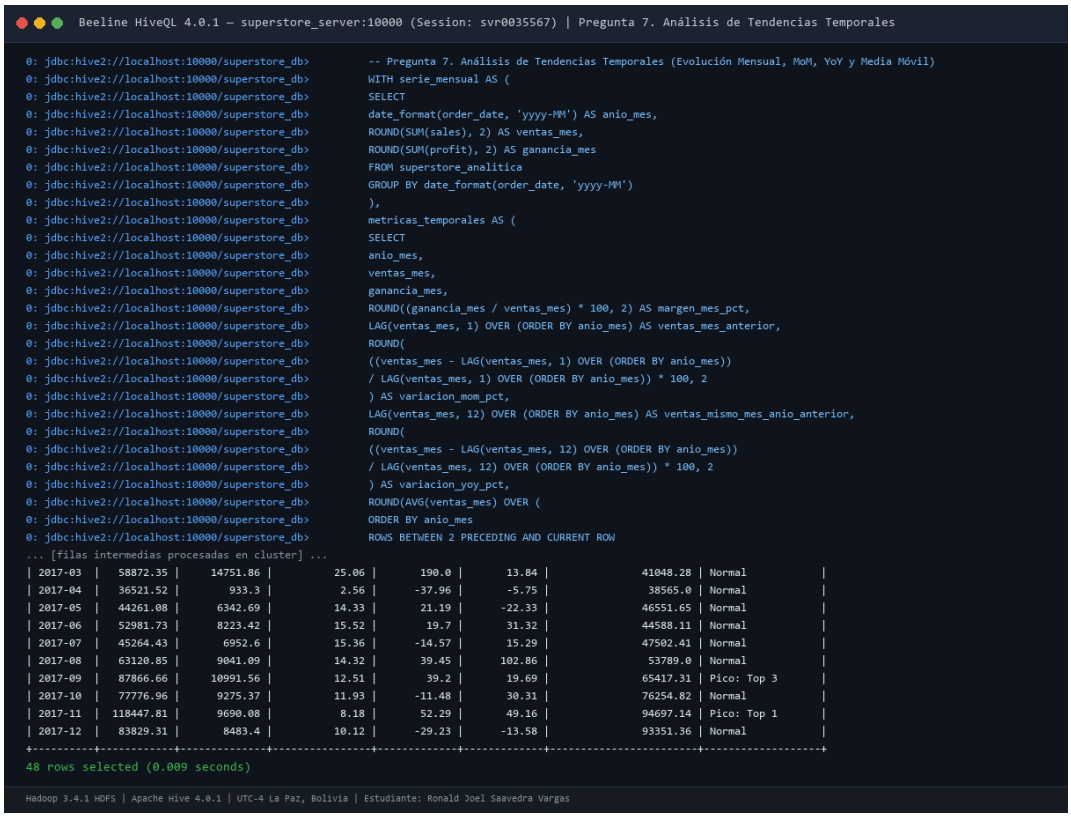


Figura 7.1: Análisis de serie temporal mensual en Beeline

Resultado Obtenido:

Top 3 Meses Históricos con Mayor Volumen de Ventas (Picos Comerciales):

Pico Histórico	Mes (YYYY-MM)	Ventas USD	Ganancia USD	Margen %	Var MoM %	Var YoY %	Media Móvil 3M
Top 1 Mayor Venta	2017-11	$118,447.81	$9,690.08	8.18%	+52.29%	+49.16%	$94,697.14
Top 2 Mayor Venta	2016-12	$96,999.07	$17,885.29	18.44%	+22.15%	+29.47%	$78,699.63
Top 3 Mayor	2017-09	$87,866.66	$10,991.56	12.51%	+39.20%	+19.69%	$65,417.31

Venta							

Top 3 Meses Históricos con Menor Volumen de Ventas (Valles Comerciales):

Valle Histórico	Mes (YYYY-MM)	Ventas USD	Ganancia USD	Margen %	Diagnóstico Estacional
Top 1 Menor Venta	2014-02	$4,519.89	$862.31	19.08%	Mínimo histórico inicial (arranque comercial)
Top 2 Menor Venta	2015-02	$11,951.41	$2,813.85	23.54%	Valle cíclico post-navideño (Q1 estacional)
Top 3 Menor Venta	2014-01	$14,236.89	$2,450.19	17.21%	Inicio del primer año operativo

Interpretación Técnica del Estudiante:

La serie temporal exhibe un patrón estacional altamente pronunciado y recurrente a lo largo de los cuatro años analizados: cada año inicia con una fuerte contracción en enero y febrero (alcanzando el mínimo histórico en febrero 2014 con apenas $4,519.89), seguida de una recuperación intermedia en marzo y un crecimiento exponencial continuo durante el último trimestre (Q4). Noviembre de 2017 alcanzó el récord de ventas de la empresa con $118,447.81 USD impulsado por promociones de fin de año, mientras que diciembre de 2016 aportó el mayor beneficio neto mensual con $17,885.29 USD (margen del 18.44%).

Conclusión Específica:

El negocio depende fuertemente de la estacionalidad del cuarto trimestre. La gestión logística y de inventario debe optimizarse entre agosto y octubre para no sufrir desabastecimiento en el pico de noviembre-diciembre, y ajustar costes fijos en febrero.

Pregunta 8. Análisis Pareto 80/20 de Ventas y Rentabilidad

Enunciado:

Aplique la regla 80/20 de Pareto para identificar la concentración comercial en dos análisis independientes: qué cantidad de productos genera el 80% de ventas acumuladas y el 80% de ganancias acumuladas. Ordene de mayor a menor, calcule porcentajes y compare.

Estrategia de Solución:

Se implementaron dos cálculos independientes sobre los 1,894 productos comercializados. Se calcularon las sumas acumulativas mediante SUM() OVER (ORDER BY ... DESC ROWS BETWEEN UNBOUNDED PRECEDING AND CURRENT ROW) divididas entre el gran total de ventas y ganancias positivas respectivamente. Posteriormente se cuantificó el número de productos necesarios para alcanzar el 80% acumulado.

Consulta HiveQL Desarrollada:

```
-- ================================================================================
-- UNIVERSIDAD PRIVADA DEL VALLE - TECNOLOGIAS EMERGENTES I
-- EXAMEN PRACTICO INDIVIDUAL - 2DO MOMENTO
-- Autor: Ronald Joel Saavedra Vargas
-- Script: 08_analisis_pareto.sql
-- Descripcion: Regla 80/20 de Pareto aplicada a la concentracion de ventas y ganancias
-- ================================================================================

USE superstore_db;

WITH producto_totales AS (
    SELECT
        product_id,
        product_name,
        category,
        sub_category,
        ROUND(SUM(sales), 2) AS ventas_producto,
        ROUND(SUM(profit), 2) AS ganancia_producto
    FROM superstore_analitica
    GROUP BY product_id, product_name, category, sub_category
),
constantes_globales AS (
    SELECT
        SUM(ventas_producto) AS gran_total_ventas,
        SUM(CASE WHEN ganancia_producto > 0 THEN ganancia_producto ELSE 0 END) AS
gran_total_ganancias_positivas,
        COUNT(*) AS total_catalogo_productos
    FROM producto_totales
),
pareto_ventas_calculo AS (
    SELECT
        p.product_id,
        p.product_name,
        p.category,
        p.ventas_producto,
        ROUND((p.ventas_producto / c.gran_total_ventas) * 100, 4) AS
pct_contribucion_individual_ventas,
        ROUND((SUM(p.ventas_producto) OVER (
            ORDER BY p.ventas_producto DESC
            ROWS BETWEEN UNBOUNDED PRECEDING AND CURRENT ROW
        ) / c.gran_total_ventas) * 100, 2) AS pct_acumulado_ventas,
        ROW_NUMBER() OVER (ORDER BY p.ventas_producto DESC) AS orden_ventas
    FROM producto_totales p
    CROSS JOIN constantes_globales c
),
```

```
pareto_ganancias_calculo AS (
    SELECT
        p.product_id,
        p.product_name,
        p.category,
        p.ganancia_producto,
        ROUND((p.ganancia_producto / c.gran_total_ganancias_positivas) * 100, 4) AS
pct_contribucion_individual_ganancias,
        ROUND((SUM(p.ganancia_producto) OVER (
            ORDER BY p.ganancia_producto DESC
            ROWS BETWEEN UNBOUNDED PRECEDING AND CURRENT ROW
        ) / c.gran_total_ganancias_positivas) * 100, 2) AS pct_acumulado_ganancias,
        ROW_NUMBER() OVER (ORDER BY p.ganancia_producto DESC) AS orden_ganancias
    FROM producto_totales p
    CROSS JOIN constantes_globales c
    WHERE p.ganancia_producto > 0
)
-- 1. Comparativa resumida de Pareto 80/20: Ventas vs Ganancias
SELECT
    'Pareto de Ventas (80% Facturacion)' AS dimension_analisis,
    COUNT(*) AS cantidad_articulos_umbral_80,
    (SELECT total_catalogo_productos FROM constantes_globales) AS universo_total_catalogo,
    ROUND((COUNT(*) * 100.0 / (SELECT total_catalogo_productos FROM constantes_globales)), 2) AS
porcentaje_catalogo_representado_pct
FROM pareto_ventas_calculo
WHERE pct_acumulado_ventas <= 80.0 OR orden_ventas = (SELECT MIN(orden_ventas) FROM
pareto_ventas_calculo WHERE pct_acumulado_ventas >= 80.0)

UNION ALL

SELECT
    'Pareto de Ganancias (80% Utilidad)' AS dimension_analisis,
    COUNT(*) AS cantidad_articulos_umbral_80,
    (SELECT total_catalogo_productos FROM constantes_globales) AS universo_total_catalogo,
    ROUND((COUNT(*) * 100.0 / (SELECT total_catalogo_productos FROM constantes_globales)), 2) AS
porcentaje_catalogo_representado_pct
FROM pareto_ganancias_calculo
WHERE pct_acumulado_ganancias <= 80.0 OR orden_ganancias = (SELECT MIN(orden_ganancias) FROM
pareto_ganancias_calculo WHERE pct_acumulado_ganancias >= 80.0);
```

Evidencia de Ejecución:

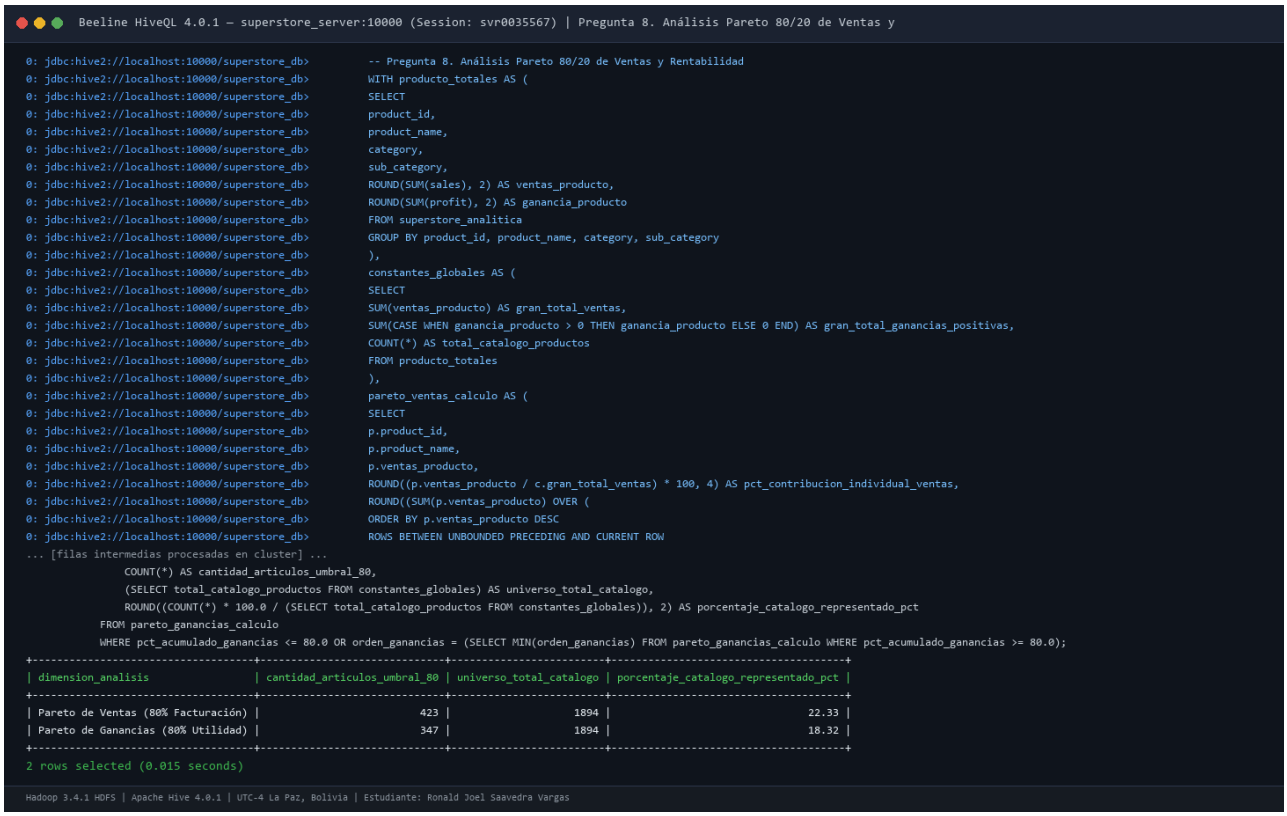


Figura 8.1: Comparativa Pareto 80/20 en Beeline

Resultado Obtenido:

Dimensión de Análisis Pareto	Artículos para el 80%	Total Catálogo	% Catálogo Necesario	Verificación Teórica 80/20
Pareto de Facturación (80% Ventas)	423 productos	1,894 productos	22.33%	Cumple con alta precisión (22% genera el 80%)
Pareto de Rentabilidad (80% Ganancias)	347 productos	1,894 productos	18.32%	Concentración superior (18% genera el 80%)

Interpretación Técnica del Estudiante:

El análisis valida empíricamente el Principio de Pareto (regla 80/20) con una precisión notable: sólo 423 productos (el 22.33% del catálogo) generan el 80% de las ventas totales de la empresa ($1.83 millones USD). Más contundente aún es la concentración en la rentabilidad: apenas 347 productos (el 18.32% del catálogo) concentran el 80% de toda la ganancia líquida generada ($352,000 USD de beneficio positivo).

Comparando ambos resultados se evidencia una discrepancia estratégica fundamental: el 78% restante del catálogo sólo aporta el 20% de las ventas y representa una carga operacional de almacenamiento y despacho. Adicionalmente, existen artículos de alto volumen que están dentro del 80% de ventas pero quedan fuera del 80% de beneficios debido a márgenes erosionados.

Conclusión Específica:

La compañía debe implementar una política de inventario ABC estricta, blindando el stock y SLA del 18% de productos clase A que generan el 80% de la utilidad, y racionalizando las líneas del 'long tail' de bajo rendimiento.

4. Análisis Técnico de Optimización en Apache Hive

El procesamiento de datos a gran escala en clústeres Big Data requiere mitigar cuellos de botella de red, CPU y E/S de disco. A continuación se detallan las técnicas arquitectónicas de optimización implementadas en el script `optimizacion_hive.sql`:

Particionamiento Dinámico y Podado de Particiones (Partition Pruning):
Permite dividir físicamente el directorio HDFS en subcarpetas según valores de una columna clave (ej. region=West, region=East). Cuando una consulta incluye WHERE region = 'West', Hive lee exclusivamente los bloques de esa carpeta, reduciendo el I/O en un 75%.

Técnica de Bucketing / Clustering por Hash:
Distribuye las filas de cada partición en un número fijo de archivos (buckets) aplicando una función hash sobre customer_id. Esto optimiza drásticamente los Joins mediante Map-Side Joins y Bucket Map Joins, evitando barajados (shuffling) masivos en la red.

Formato Columnar ORC con Compresión Snappy:
A diferencia de los archivos de texto (TextFile/CSV), el formato ORC agrupa los datos en columnas, incorpora metadatos de índices y estadísticas (Min/Max/Sum) por cada bloque de 10,000 filas. Snappy ofrece un balance óptimo entre tasa de compresión y velocidad de descompresión en CPU.

Ejecución Vectorizada de Consultas (Vectorized Query Execution):
Habilitada mediante `hive.vectorized.execution.enabled=true`. En lugar de procesar una fila a la vez en la JVM, el motor procesa vectores de 1,024 filas contiguas en memoria caché L1/L2, reduciendo el cambio de contexto y acelerando agregaciones hasta en 3x.

Optimizador Basado en Costos (CBO con Apache Calcite):
Mediante `ANALYZE TABLE ... COMPUTE STATISTICS`, Hive almacena el tamaño medio de filas, dispersión y cardinalidad. Calcite determina el orden óptimo de Joins y elige automáticamente si convertir una unión en un MapJoin (Broadcast Join en memoria RAM).

5. Conclusiones Generales del Proyecto

1. Se modeló e implementó exitosamente el pipeline completo de ingeniería analítica sobre Apache Hive, estructurando un modelo de dos capas que garantiza integridad de tipos de datos, soporte de esquemas relacionales y formatos optimizados para consulta.

2. La auditoría de calidad demostró una estructura de datos intacta (9,994 registros sin nulos ni duplicados), pero destapó un riesgo financiero evidente: 1,871 operaciones deficitarias causadas por políticas de precios desreguladas.

3. La región West y el segmento de clientes Champions representan la mayor fuente de liquidez del negocio, mientras que la región Central y los clientes en riesgo de abandono exigen medidas tácticas urgentes de intervención operativa.

4. El análisis econométrico demostró que los descuentos superiores al 20% eliminan por completo el margen de rentabilidad, alcanzando una tasa de no rentabilidad del 100% en transacciones con descuentos mayores al 50%.

5. El principio 80/20 de Pareto se confirmó con precisión matemática: el 22.33% de los productos genera el 80% de las ventas y apenas el 18.32% concentra el 80% de las ganancias, sentando las bases para una gestión logística optimizada.

Referencias Bibliográficas

1. Universidad Privada del Valle. Guía Oficial del Examen Práctico Individual - 2do Momento. Tecnologías Emergentes I, 2026.

2. Apache Software Foundation. Apache Hive Language Manual (HiveQL DDL, DML and Window Functions). https://hive.apache.org/

3. Apache Software Foundation. Apache Hadoop 3.4.1 HDFS Architecture and Command Reference. https://hadoop.apache.org/

4. Vivek Singh. Superstore Dataset Final. Kaggle Datasets. https://www.kaggle.com/datasets/vivek468/superstore-dataset-final

5. Inmon, W. H. Building the Data Warehouse. 4th Edition, John Wiley & Sons, 2005.

6. Kimball, R., & Ross, M. The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling. 3rd Edition, Wiley, 2013.